# 18 – Testando Escalabilidade no Kubernetes – Vertical Pod Autoscaler

Os objetivos dessa prática são:

- Fazer o deploy de uma aplicação básica;
- Instalar o Vertical Auto Scaler;
- Estressar a CPU do pod com a aplicação básica;
- Verificar as sugestões do tamanho do pod após a realização do teste de estresse da CPU.

Para realizar essa prática é preciso ter instalado um cluster Kubernetes, o protocolo openssI na versão 11 e o GIT.

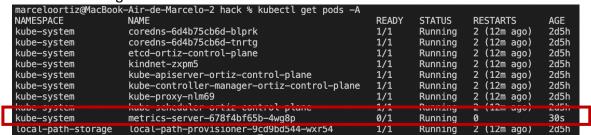
### Passo a Passo

Para configurar o Vertical Auto Scaler é preciso, primeiro, fazer o deploy do servidor que faz a coleta das métricas dos Nodes e dos Pods. Para isso:

 No terminal onde está o seu cluster do Kubernetes, digite o comando "kubectl apply -f <a href="https://github.com/kubernetes-sigs/metrics-server/releases/latest/download/components.yaml">https://github.com/kubernetes-sigs/metrics-server/releases/latest/download/components.yaml</a>

 $\begin{tabular}{ll} \$ \ kubectl \ apply \ -f \ https://github.com/kubernetes-sigs/metrics-server/releases/latest/download/components.yaml \end{tabular}$ 

2) Digite o comando "kubectl get pods -A" e verifique se o POD "metrics-server" está em "running":



3) Verifique os eventos do seu pod "metrics-server", caso exista alguma falha com "HTTP probe failed with statuscode: 500" siga o passo 4, caso contrário siga para o passo 6:

Para verificar os eventos do pod, digite: kubectl describe pods -n kube-system "nome do pod de métricas":

kubectl describe pods -n kube-system metrics-server-678f4bf65b-4wg8p

O evento com erro é:



4) Para corrigir esse erro, será preciso editar o POD "metrics-server" e adicionar as linhas abaixo na especificação do containers:

#### command:

- /metrics-server
- --kubelet-insecure-tls
- --kubelet-preferred-address-types=InternalIP

Para isso digite "kubectl edit deploy -n kube-system metrics-server:

## kubectl edit deploy -n kube-system metrics-server

Pressione a tecla "i" e insira as linhas acima logo abaixo da linha "- --metric-resolution=15s"

Cuidado com a indentação, pois as novas linhas precisam iniciar na mesma coluna das demais linhas.

Saia salvando, pressionando a tecla "esc" e depois digitando ":wq".

5) Verifique se agora o POD do "metrics-server" está em execução sem nenhum erro nos últimos eventos, para isso digite "kubectl describe pods -n kubesystem "nome do pod do metric server":



6) Veja que agora é possível executar os comandos "kubectl top pods -A" e "kubectl top nodes". Esse comando vai trazer a utilização de CPU e memória dos seus PODs e Nodes.

```
marceloortiz@MacBook-Air-de-Marcelo-2 hack % kubectl top nodes
NAME CPU(cores) CPU% MEMORY(bytes) MEMORY%
ortiz-control-plane 240m 6% 747Mi 18%
```

marceloortiz@MacBook-Air-de-Marcelo-2 hack % kubectl top pods -A			
NAMESPACE	NAME	CPU(cores)	MEMORY(bytes)
kube-system	coredns-6d4b75cb6d-blprk	7m	12Mi
kube-system	coredns-6d4b75cb6d-tnrtg	6m	12Mi
kube-system	etcd-ortiz-control-plane	30m	48Mi
kube-system	kindnet-zxpm5	2m	10Mi
kube-system	kube-apiserver-ortiz-control-plane	82m	319Mi
kube-system	kube-controller-manager-ortiz-control-plane	31m	42Mi
kube-system	kube-proxy-nlm69	1m	10Mi
kube-system	kube-scheduler-ortiz-control-plane	6m	16Mi
kube-system	metrics-server-69cb89695d-t5ll5	10m	18Mi
local-path-storage	local-path-provisioner-9cd9bd544-wxr54	3m	6Mi

Agora já podemos fazer o deploy de uma aplicação qualquer. No nosso caso vamos fazer um deploy de um nginx. Essa aplicação que vamos fazer a configuração do HPA.

7) Crie um arquivo com o nome "deploy.yaml" com as informações abaixo:

```
apiVersion: apps/v1
kind: Deployment
metadata:
name: scaling-deploy
spec:
replicas: 1
selector:
matchLabels:
app: nginx
template:
metadata:
labels:
app: nginx
spec:
containers:
- name: nginx
image: nginx
resources:
requests:
memory: "50Mi"
cpu: "500m"
```

8) Faça o deploy desse arquivo com o comando "kubectl apply -f deploy.yaml":

```
marceloortiz@MacBook-Air-de-Marcelo-2 k8s % kubectl apply -f deploy.yaml
deployment.apps/scaling-deploy created
```

9) Verifique o consumo desse POD com o comando "kubectl top pods":

```
marceloortiz@MacBook-Air-de-Marcelo-2 k8s % kubectl top pods
NAME CPU(cores) MEMORY(bytes)
scaling-deploy-8f458dc5b-4z699 0m 6Mi
```

Veja que o consumo de CPU está bem baixo.

Agora vamos instalar o Vertical Auto Scaler, para isso:

10) No diretório de sua preferência, faça o clone do repositório do VPA com o comando "git clone <a href="https://github.com/kubernetes/autoscaler.git">https://github.com/kubernetes/autoscaler.git</a>":

```
marceloortiz@MacBook-Air-de-Marcelo-2 k8s % git clone https://github.com/kubernetes/autoscaler.git Cloning into 'autoscaler'...
remote: Enumerating objects: 153436, done.
remote: Counting objects: 100% (1/1), done.
remote: Total 153436 (delta 0), reused 0 (delta 0), pack-reused 153435
Receiving objects: 100% (153436/153436), 163.83 MiB | 32.35 MiB/s, done.
Resolving deltas: 100% (98420/98420), done.
Updating files: 100% (28564/28564), done.
```

- 11) Entre no diretório de instalação do VPA, com o comando "cd /autoscaler/vertical-pod-autoscaler/hack";
- 12) Execute a instalação com o comando "./vpa-up.sh":

```
marceloortiz@MacBook-Air-de-Marcelo-2 hack % ./vpa-up.sh customresourcedefinition.apiextensions.k8s.io/verticalpodautoscalercheckpoints.autoscaling.k8s.io created customresourcedefinition.apiextensions.k8s.io/verticalpodautoscalers.autoscaling.k8s.io created clusterrole.rbac.authorization.k8s.io/system:metrics-reader created clusterrole.rbac.authorization.k8s.io/system:vpa-actor created clusterrole.rbac.authorization.k8s.io/system:vpa-checkpoint-actor created clusterrole.rbac.authorization.k8s.io/system:evictioner created clusterrolebinding.rbac.authorization.k8s.io/system:metrics-reader created clusterrolebinding.rbac.authorization.k8s.io/system:vpa-actor created clusterrolebinding.rbac.authorization.k8s.io/system:vpa-actor created clusterrolebinding.rbac.authorization.k8s.io/system:vpa-checkpoint-actor created
```

13) Agora é preciso fazer o deploy da configuração do VPA, para isso, crie um arquivo chamado "vpa.yaml" com o conteúdo abaixo:

```
apiVersion: autoscaling.k8s.io/v1
kind: VerticalPodAutoscaler
metadata:
   name: scaling-deploy
spec:
   targetRef:
    apiVersion: apps/v1
   kind: Deployment
    name: scaling-deploy
updatePolicy:
   updateMode: "Off" #Auto
```

14) Faça o deploy desse arquivo com o comando "kubectl create -f vpa.yaml":

```
marceloortiz@MacBook-Air-de-Marcelo-2 k8s % kubectl create -f vpa.yaml
verticalpodautoscaler.autoscaling.k8s.io/scaling-deploy created
```

15) Para ver as informações do VPA, digite o comando "kubectl get vpa":

```
marceloortiz@MacBook-Air-de-Marcelo-2 k8s % kubectl get vpa
NAME MODE CPU MEM PROVIDED AGE
scaling-deploy Off 25m 262144k True 74s
```

16) Para verificar a sugestão do VPA para o tamanho do POD que ele está analisando, digite o comando "kubectl describe vpa "nome do pod":

```
INCCOMME
Recommendation:
  Container Recommendations:
    Container Name:
                      nginx
    Lower Bound:
      Cpu:
                25m
                262144k
      Memory:
    Target:
      Cpu:
                25m
      Memory:
                262144k
    Uncapped Target:
                25m
      Cpu:
                262144k
      Memory:
    Upper Bound:
                999m
      Cpu:
                1045422996
      Memory:
```

- 17) A recomendação fica na seção "Target", que no nosso exemplo está com Cpu de 25m e memoria de 262144k.
- 18) Agora vamos estressar o nosso pod, para isso, conecte no bash do POD que foi deployado no passo 8, para isso digite o comando "kubectl -it exec nome\_do\_pod -- bash":

```
marceloortiz@MacBook-Air-de-Marcelo-2 k8s % kubectl -it exec scaling-deploy-6686b77c59-s8tg9 -- bash root@scaling-deploy-6686b77c59-s8tg9:/# ■
```

19) Dentro do POD, execute os comandos "apt update && apt install stress":

```
root@scaling-deploy-6686b77c59-s8tg9:/# apt update && apt install stress
Get:1 http://deb.debian.org/debian bullseye InRelease [116 kB]
Get:2 http://deb.debian.org/debian-security bullseye-security InRelease [48.4 kB]
Get:3 http://deb.debian.org/debian bullseye-updates InRelease [44.1 kB]
Get:4 http://deb.debian.org/debian bullseye/main arm64 Packages [8069 kB]
Get:5 http://deb.debian.org/debian-security bullseye-security/main arm64 Packages [167 kB]
Get:6 http://deb.debian.org/debian bullseye-updates/main arm64 Packages [2600 B]
```

20) Ainda dentro do POD, digite o comando "stress --cpu 1" e aguarde 5 minutos:

```
root@scaling-deploy-6686b77c59-s8tg9:/# stress --cpu 1 stress: info: [317] dispatching hogs: 1 cpu, 0 io, 0 vm, 0 hdd
```

21) Finalize o processo do stress pressionando as teclas "ctl" + "c" e saia do POD digitando o comando "exit";

22) Agora verifique as novas recomendações do VPA, para isso digite o comando "kubectl describe vpa":

```
Recommendation:
 Container Recommendations:
    Container Name:
                     nginx
    Lower Bound:
      Cpu:
               25m
     Memory:
               262144k
    Target:
      Cpu:
               1168m
     Memory: 262144k
    Uncapped Target:
      Cpu:
               1168m
     Memory:
               262144k
    Upper Bound:
               61272m
      Cpu:
     Memory: 2600215673
```

Veja que agora, ele já trás novas recomendações de configuração do POD, com o target de CPU de 1168m e de memória de 262144k.

## 23) Para limpar o ambiente:

- a. Remova a instalação do VPA, para isso, no diretório "autoscaler/vertical-pod-autoscaler/hack" digite o comando "./vpa-down.sh":
- b. Remova o deploy da aplicação utilizada como exemplo, digitando o comando "kubectl delete -f deploy.yaml".